

MEMORIA PRÁCTICA DE DEEP LEARNING

1. Introducción

En esta práctica se trabajó con un dataset de POIs (puntos de interés) que incluía imágenes y varios metadatos como likes, visitas, bookmarks, etc. El objetivo era construir un modelo capaz de predecir si un POI tendría alto engagement. Como el dataset no venía etiquetado, primero fue necesario crear la variable objetivo. Después, se prepararon los datos, se diseñó un modelo multimodal (que combina imágenes y metadatos), se entrenó y finalmente se evaluó.

Se intentó seguir todos los pasos vistos en clase, explicándolos de forma sencilla para demostrar la comprensión del proceso realizado.

2. Preparación y Análisis de Datos

2.1 Análisis exploratorio

Antes de entrenar el modelo, se revisó el dataset para entenderlo:

- Se observó la distribución de likes, visitas y otras métricas.
- Se revisó si había valores raros o extremos.
- Se comprobó si había valores faltantes.
- Se analizaron las variables categóricas, que tenían muchas categorías distintas.

Este paso ayudó a saber qué preprocesamientos era necesario aplicar.

2.2 Preprocesamiento

➤ Imágenes

Las imágenes venían en tamaños diferentes, por lo que se redimensionaron a 224×224 y se normalizaron con los valores estándar de ImageNet. También se añadió data augmentation (rotaciones, flips, cambios de brillo) para que el modelo aprendiera a generalizar mejor.

➤ Valores faltantes

- En numéricas: se imputó con la media del conjunto de entrenamiento.
- En categóricas: se usó un token especial UNKNOWN.

➤ Codificación de categóricas

Como había miles de categorías, usar one-hot encoding no tenía sentido. Por eso se utilizaron embeddings, que permiten representar cada categoría como un vector pequeño y eficiente.

➤ Creación de la variable de engagement

Como no había etiquetas, se creó una métrica propia:

$$\text{engagement} = \text{likes} + \text{bookmarks} - \text{dislikes}$$

Luego convertí esta métrica en una etiqueta binaria usando el percentil 75:

- 1 → alto engagement
- 0 → bajo engagement

Esto permitió equilibrar las clases y centrarse en los POIs más relevantes.

➤ División del dataset

Los datos se dividieron en:

- 70% entrenamiento
- 15% validación
- 15% test

Se utilizó stratify para mantener la proporción de clases.

3. Arquitectura del Modelo

Se diseñó un modelo multimodal, es decir, que combina dos tipos de información:

3.1 Rama visual

Se utilizó una ResNet18 preentrenada porque es ligera y funciona bien con imágenes. Se eliminó la última capa y se añadieron capas fully-connected propias con dropout.

3.2 Rama contextual

En esta rama se procesaron:

- variables numéricas (normalizadas)
- variables categóricas (convertidas en embeddings)

También se añadieron capas fully-connected y dropout.

3.3 Fusión

Una vez procesadas ambas ramas, se concatenaron los vectores y se pasaron por un MLP final que devuelve una probabilidad entre 0 y 1.

3.4 Justificación

Esta arquitectura se eligió porque:

- las CNN son muy buenas con imágenes
- los embeddings funcionan muy bien con categorías

- la fusión permite aprovechar ambas fuentes de información
- el dropout y el early stopping ayudan a evitar sobreajuste

Se intentó ser cuidadosa para evitar data leakage, usando siempre solo el conjunto de entrenamiento para ajustar transformaciones.

4. Entrenamiento y Optimización

4.1 Configuración

- Pérdida: BCELoss
- Optimizador: Adam ($lr=1e-4$)
- Épocas: 20
- Early stopping con paciencia 5

4.2 Resultados del entrenamiento

La pérdida de entrenamiento bajó muy rápido, pero la de validación solo mejoró en las dos primeras épocas y luego empezó a subir. Esto indica sobreajuste, algo normal en datasets pequeños.

El early stopping funcionó bien y guardó el mejor modelo en la época 2.

5. Evaluación y Análisis

5.1 Métricas en test

- Accuracy: 0.85
- Precision: 0.75
- Recall: 0.73
- F1-score: 0.74

Estas métricas muestran que el modelo funciona bastante bien y supera claramente a un clasificador aleatorio.

5.2 Matriz de confusión

La matriz mostró:

- 147 verdaderos negativos
- 49 verdaderos positivos
- 24 falsos positivos
- 23 falsos negativos

El modelo acierta la mayoría de los casos, aunque le cuesta un poco más identificar los POIs de alto engagement, probablemente porque son más variados.

5.3 Curva ROC + AUC

La curva ROC mostró una buena separación entre clases y el AUC confirmó que el modelo generaliza correctamente.

5.4 Interpretabilidad con Grad-CAM

Se aplicó Grad-CAM para ver qué partes de la imagen usa la CNN para decidir. El modelo suele fijarse en:

- fachadas
- zonas con actividad
- elementos visuales llamativos

Esto ayudó a comprobar que la CNN está usando información relevante y no ruido.

6. Conclusiones

En esta práctica se aprendió a:

- preparar un dataset real
- crear una variable objetivo desde cero
- trabajar con imágenes y metadatos a la vez
- diseñar un modelo multimodal
- entrenarlo correctamente
- evaluar su rendimiento
- interpretar sus predicciones

El modelo final funciona bien y demuestra que la combinación de imágenes y metadatos es útil para predecir engagement.

7. Mejoras futuras

Aunque el resultado es satisfactorio, se considera que podría mejorarse:

- usando una CNN más potente (EfficientNet)
- aplicando data augmentation más fuerte
- probando Focal Loss para mejorar el recall
- ajustando el umbral de clasificación

- rebalanceando las clases
- aumentando el tamaño del dataset
- probando mecanismos de fusión más avanzados

Estas ideas podrían reducir los falsos positivos y falsos negativos.

8. Reproducibilidad

- Se fijaron semillas aleatorias
- Se incluye requirements.txt
- El modelo final está guardado en best_model.pth
- El notebook contiene todo el pipeline paso a paso